

”P10” Algoritmo genético

NESTOR

Mayo 2022

1. Objetivo

El objetivo de la práctica consiste en el problema de la mochila (inglés: knapsack) es un problema clásico de optimización, particularmente de programación entera, donde la tarea consiste en seleccionar un subconjunto de objetos de tal forma que (i) no se exceda la capacidad de la mochila en términos de la suma de los pesos de los objetos incluidos, y que (ii) el valor total de los objetos incluidos sea lo máximo posible [2].

2. Desarrollo

Basandome en el desarrollo en la [codificación](#) implementado por E. Schaeffer y todas las instrucciones se encuentran en el [repositorio](#) de N. Rodríguez en GitHub.

Para comenzar se hace primero generar la función para generar partículas de atracción y repulsión con esto para poder visualizar la masa

Código 1: Algoritmo de la combinación óptima.

```
1 import math
2 from scipy.stats import expon
3 from time import time
4 def knapsack(peso_permitido, pesos, valores):
5     assert len(pesos) == len(valores)
6     peso_total = sum(pesos)
7     valor_total = sum(valores)
8     if peso_total < peso_permitido:
```

Generamos las posiciones de los pesos y valores de las instancias con esto de 1 a 3.

Código 2: Pesos y Valores

```
1 def pesos(cuantos, low, high):
2     return np.round(normalizar(np.random.uniform(size = cuantos)) * (high - low) + low)
3
4 def valores(pesos, low, high):
5     n = len(pesos)
6     valores = np.empty((n))
7     for i in range(n):
8         valores[i] = np.random.uniform(pesos[i], random(), 1)
9     return normalizar(valores) * (high - low) + low
```

Para las instancias se crean $n = 40$ con los valores y pesos, a continuación se muestra la codificación:

Código 3: Parámetro de n

```
1 n = 40
2 VP=[]
3 Tr=[]
4 for regla in range(3):
5     print("##### regla:",regla,"#####")
6     if regla == 0:
7         pesos = pesos1(n, 23, 100)
8         valores = valores1(pesos, 5, 700)
9     if regla == 1:
10        valores = valores2(n, 5, 700)
11        pesos = pesos2(valores, 23, 80)
```

Se hace la combinacion de valores y pesos para poder hacer las variaciones de mutaciones, reproducciones y la poblaci3n. Con esto se genera las replicas e iteracciones.

C3digo 4: Generacion de funciones

```

1 for pm, init, rep in instancias:
2     antesi=time()
3     print("#####",pm, init, rep,"#####")
4     replicas=3
5     best=[]
6     porc_dif=[]
7     for K in range(replicas):
8         p = poblacion_inicial(n, init)
9         tam = p.shape[0]
10        assert tam == init
11        tmax = 100
12        mejor = None
13        mejores = []
14        for t in range(tmax):
15            for i in range(tam): # mutarse con probabilidad pm
16                if random() < pm:
17                    p = np.vstack([p, mutacion(p[i], n)])
18            for i in range(rep): # reproducciones
19                padres = sample(range(tam), 2)
20                hijos = reproduccion(p[padres[0]], p[padres[1]], n)
21                p = np.vstack([p, hijos[0], hijos[1]])
22            tam = p.shape[0]
23            d = []
24            for i in range(tam):
25                d.append({'idx': i, 'obj': objetivo(p[i], valores),
26                        'fact': factible(p[i], pesos, capacidad)})
27            d = pd.DataFrame(d).sort_values(by = ['fact', 'obj'], ascending = False)
28            mantener = np.array(d.idx[:init])
29            p = p[mantener, :]
30            tam = p.shape[0]
31            assert tam == init
32            factibles = d.loc[d.fact == True,]
33            mejor = max(factibles.obj)
34            mejores.append(mejor)
35            best.append(mejor)
36            porc_dif.append(((optimo - mejor) / optimo)*100)
37            CB.append(porc_dif)
38            Ti.append(time()-antesi)
39 VP.append(CB)
40 Tr.append(Ti)

```

3. Resultados

Cuadro 1: An3lisis de las instancias

| Suma de los pesos de los objetos | Mediciones | Estadística |
|----------------------------------|------------|--------------------------------|
| Instancia 1 | 0,09 | 2,997885194550087 por ciento |
| | 0,20 | 7,857709388825363 por ciento |
| | 1,0 | 5,923737554493455 por ciento |
| Instancia 2 | 23 | 1,2345504465635582 por ciento |
| | 100 | 3,0208706337084634 por ciento |
| | 40 | 0,4934503866186409 por ciento |
| Instancia 3 | 1,0 | 0,16747628028044556 por ciento |
| | 900 | 5,974668588789195 por ciento |
| | 80 | 3,0175308723987713 por ciento |

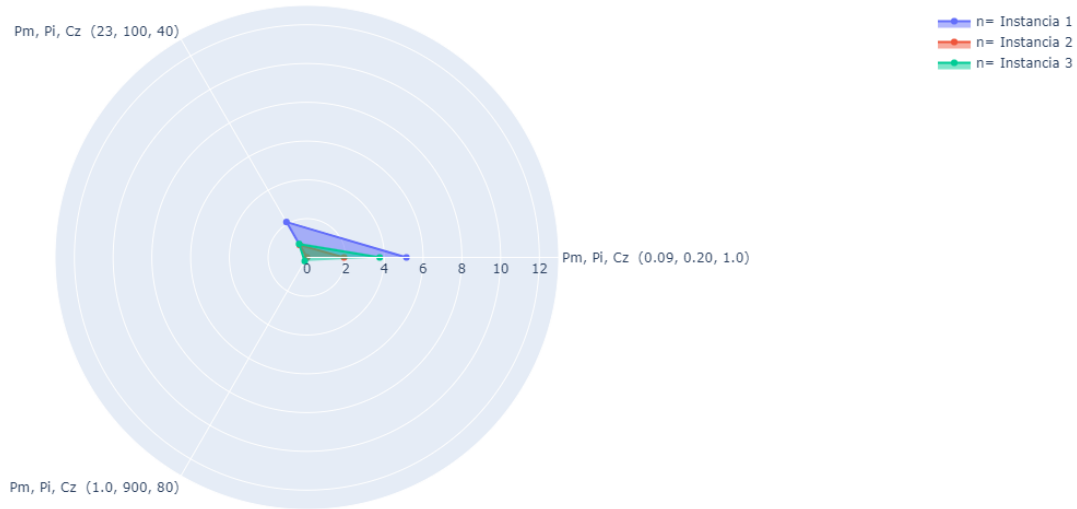


Figura 1: Analisis de los datos multivariados de las instancias.

4. Conclusiones

Como se puede apreciar en el diagrama de araña que es una herramienta muy útil para mostrar visualmente los gaps entre el estado actual y el estado ideal, se concluye que se puede implementar un algoritmo de genes para poder ejecutar problemas de complejidad en los análisis estadísticos como se observó en el cuadro de análisis de instancias ya que se varía los parámetros y con esto puede llegar a ser el valor óptimo por los valores que se pueden ejecutar con mayor fluidez.

Referencias

- [1] N. Rodríguez. "p10.algoritmo genético. *Repositorio, GitHub*, 2022. URL <https://github.com/NestorZeus/SIMULACION-COMPUTACIONAL-DE-NANOMATERIALES/tree/main/P10>.
 - [2] E. Schaeffer. Genetic algorithm. *Repositorio, GitHub*, 2022. URL <https://github.com/satuelisa/Simulation/blob/master/GeneticAlgorithm/routines.py>.
- [1] [2]